

Перенос структурного знания из синтетических языков

Краткое описание проекта (MVP). На основе статьи Budnikov & Yamshchikov, «Transfer of Structural Knowledge from Synthetic Languages» (arXiv:2505.15769).

1. Задача

Главный вопрос простой: можно ли научить модель «структуре» на искусственном языке без всякого смысла - и перенести это знание на настоящий английский, превзойдя качество модели, обученной только лишь на английском? Логика такая: берётся маленький трансформер, обучается с нуля на синтетическом языке (это просто поток токенов, со строгим правилом, без значений слов), затем «замораживается» его внутренняя часть и сравнивается, насколько она помогает с английским при дообучении.

Статья, на которой основан проект, показала, что такой перенос вообще работает. В своей работе я развиваю эту идею и проверяю следующий шаг: разные искусственные языки для тренировки разных умений - что из этого реально полезно для английского?

Чтобы это проверить, были добавлены два собственных языка, каждый под своё умение:

- **counting** - учит **считать** (отсчитать ровно n одинаковых элементов);
- **mirror** - учит **копировать и держать в памяти** (вторая половина строки - зеркало первой).

Они сравниваются с языками из статьи: **nested** (вложенные скобки, то есть «иерархия») и **flat_shuffle** (самый сильный язык оригинала). Также были рассмотрены не эмбединги, как в статье, а «внимание» модели, исследовано поведение на строках длиннее обучающих и геометрия эмбедингов.

2. Данные

Синтетические языки. Каждый - это строки фиксированной длины (128 токенов) с маленьким словарём, порождённые жёстким правилом:

Язык	Что генерирует (правило)	Какой навык
nested	сбалансированные вложенные скобки	иерархия
flat_shuffle	скобки + блочные перестановки (язык из статьи)	структура (сильный бейзлайн)
counting	блок «счётчик n » и ровно n одинаковых предметов	счёт
mirror	строка S , разделитель, затем S наоборот	копирование / память

Английский. TinyStories - простые детские рассказы с ограниченным словарём. Берём текст потоком и делим на части по 128 токенов. TinyStories использует лишь малую часть словаря GPT-Neo (~50 тыс.), поэтому пересобираем компактный словарь только из встречающихся токенов (~5 900) - так каждый эмбединг реально обучается, а не остаётся случайным.

Модель. TinyStories-8M - та же архитектура, что в статье (GPT-Neo, скрытый размер 256, ~7 млн параметров). Веса всегда инициализируем с нуля: синтетический претрейн не должен «видеть» английский.

3. Методы

Эксперимент в три шага:


1. **Претрейн.** обучение модели с нуля на синтетическом языке (учатся все веса).

2. **Перенос.** Заморозка «тела» трансформера, заново случайно инициализируем эмбединги под английский и дообучаем либо только эмбединги (режим E), либо эмбединги + нормализацию + последний блок (режим ELT).
3. **Оценка.** Считаем перплексию на английском и переводим её в Efficiency Score = $\text{ppl}(\text{scratch}) / \text{ppl}(\text{модель}) \times 100\%$. Здесь scratch - эталон, обученный на английском с нуля; 100% = его уровень. Нормировка на scratch того же сида, поэтому числа усредняются. Вторая метрика - cloze-accuracy: 30 вопросов «вставь слово», доля правильных выборов.

Каждый эксперимент был проведен на 3 сидах, чтобы получить доверительные интервалы (mean $\pm$ std), а не одно случайное число, и сравнен с бейзлайнами из статьи. Отдельно посчитаны карты внимания (на какую дистанцию смотрят головы и насколько они сфокусированы), деградация метрик на строках длиннее обучающих и геометрия эмбедингов (изотропия).

4. Результаты

Язык	Efficiency (% от scratch)	cloze-acc
nested (статья)	104 $\pm$ 8 %	58 $\pm$ 7 %
flat_shuffle (статья)	91 $\pm$ 1 %	64 $\pm$ 11 %
counting (новый)	84 $\pm$ 2 %	68 $\pm$ 4 %
mirror (новый)	18 $\pm$ 3 %	58 $\pm$ 2 %



Эффективность переноса (3 сида). Пунктир - уровень scratch (100%).

Главное:

1. **Лучше всех переносится иерархия (nested) - 104%, на уровне эталона и даже чуть выше.** Новые языки её не победили: оба языка статьи оказались выше новых. Однако язык counting очень близок к flat_shuffle. Разница <10%, возможно, результат будет другой при большем объеме данных и экспериментах.
2. **counting уступает обоим языкам статьи (84%), но переносится стабильнее** - разброс по сидам у него маленький.
3. **mirror – худший по эффективности (18%),** хотя само копирование он выучивает почти идеально и по вниманию у него самые длинные и острые головы. Это главный вывод: то, что язык сложнее устроен, не делает его полезнее для английского.

4. По вниманию mirror выделяется (самые дальнобойные и острые головы), но чистой «зеркальной головы» не нашлось - внимание слабое и размазанное, это является косвенным признаком. По cloze языки почти неразличимы (чуть выше других counting, 68%).

P.S. Почему nested получает 104%, а не максимум 100%? Это не ошибка: 100% - не потолок, а просто уровень scratch. Перенос может его и превысить, потому что в режиме ELT мы дообучаем меньше параметров поверх уже структурированного «тела» - это естественная регуляризация, поэтому на ограниченном английском корпусе модель меньше переобучается. Плюс оценка перплексии шумит, и интервал $104 \pm 8\%$ всё равно перекрывает 100% - то есть формально nested статистически неотличим от scratch.

Практический вывод. Разные синтетические языки развивают разные, почти не пересекающиеся умения. Значит, искать один «лучший для всего» язык - неправильно; перспективнее обучать модель на смеси разных языков, меняя их пропорции и порядок подачи, чтобы подобрать наилучшую комбинацию.

Оговорки. Это первая версия исследования: мало шагов и всего 3 сида, числа заметно шумят между прогонами. Nested особенно нестабилен - здесь у него самый большой разброс по сидам. Анализ внимания, метрики на длинных строках и изотропию считали на одном сиде – в будущем стоит усреднить значения нескольких экспериментов с разными сидами.